

**UNIVERSIDADE PRESBITERIANA MACKENZIE**  
**CURSO DE TECNOLOGIA EM CIÊNCIA DE DADOS**

ANDRÉ CAVINA OLIVEIRA

DIOGO SILVA

FELIPE GRACIANO

**ANÁLISE DE SATISFAÇÃO – ESTUDO DE CASO IFOOD**

ANDRÉ CAVINA OLIVEIRA

DIOGO SILVA

FELIPE GRACIANO

## **ANÁLISE DE SATISFAÇÃO – ESTUDO DE CASO IFOOD**

Este trabalho foi desenvolvido no âmbito do Projeto Aplicado I, com o propósito de aplicar conceitos de Ciência de Dados em um estudo real. O grupo escolheu como tema a análise da satisfação do cliente em serviços de delivery, tomando como exemplo a empresa iFood.

## RESUMO

Este projeto, desenvolvido no âmbito do Projeto Aplicado I, visa analisar os fatores que determinam a satisfação de clientes em plataformas de delivery, tomando como estudo de caso o iFood. Utilizando o *Brazilian E-Commerce Dataset by Olist* (2016–2018), foram aplicadas técnicas de análise exploratória e modelagem preditiva para identificar os principais determinantes das avaliações de pedidos.

Os resultados apontam que o **atraso na entrega (delay\_days)** é o fator com maior impacto negativo sobre a nota de satisfação (*review\_score*), superando variáveis financeiras como preço e valor do frete. Essa evidência reforça a importância da gestão logística e da comunicação proativa com o cliente.

O projeto propõe ainda a segmentação de clientes sensíveis a atrasos e apresenta recomendações operacionais para reduzir avaliações negativas.

Palavras-chave: iFood, Olist, satisfação do cliente, entrega, regressão linear, análise exploratória de dados, logística.

## Sumário

|                                                                   |    |
|-------------------------------------------------------------------|----|
| RESUMO.....                                                       | 3  |
| 1 PROJETO.....                                                    | 5  |
| 2 PREPARAÇÃO E INTEGRAÇÃO DOS DADOS .....                         | 5  |
| 2.1 Reprodutibilidade da Integração de Dados:.....                | 6  |
| 3 ANALISE EXPLORATÓRIA (EDA) .....                                | 6  |
| 3.1 As Primeiras Pistas: Correlações Relevantes.....              | 8  |
| 3.2 O Fator Crítico: Análise Logística.....                       | 8  |
| 4 GERAÇÃO DE INSIGHTS E MODELAGEM PREDITIVA.....                  | 9  |
| 5. PLANEJAMENTO DE SEGMENTAÇÕES.....                              | 11 |
| 6. SÍNTESE FINAL E AÇÕES FUTURAS .....                            | 11 |
| 6.1 Investigação.....                                             | 12 |
| 6.2 Análise da Variável-Alvo: review_score .....                  | 12 |
| 6.3 Análise dos Fatores Explicativos: Logística vs. Finanças..... | 13 |
| 6.4 A Causa Raiz: O Impacto do Atraso .....                       | 13 |
| 6.5 Conclusão: .....                                              | 14 |
| 7. CONSIDERAÇÕES FINAIS.....                                      | 14 |
| APÊNDICE .....                                                    | 15 |

# 1 PROJETO

Link do GitHub: [https://github.com/Cavinnatto/projeto\\_aplicado\\_I](https://github.com/Cavinnatto/projeto_aplicado_I)

Análise de Satisfação de Clientes — iFood / Olist

Data: 13 de novembro de 2025

Fase Atual: Etapa 3 — Storytelling e Visualizações

A análise parte da seguinte pergunta de pesquisa:

*Quais fatores mais impactam a avaliação do cliente em pedidos realizados via e-commerce?*

O estudo busca oferecer à empresa insights acionáveis que sustentem melhorias operacionais e aumento de fidelização.

## **Escopo e resultados esperados:**

- Entregar um dataset consolidado e reprodutível (merged\_dataset.csv).
- Produzir EDA documentada e visualizações interpretáveis.
- Construir e validar um modelo preditivo (regressão linear) para quantificar impacto das variáveis explicativas.
- Gerar recomendações operacionais e plano de segmentação para reduzir avaliações negativas.

## **Persona Representativa:**

Maria, 29 anos, realiza pedidos semanalmente e valoriza pontualidade mais do que preço. Quando o pedido atrasa, tende a avaliar negativamente o serviço, demonstrando sensibilidade à confiabilidade da entrega.

## **Resumo Executivo (Storytelling):**

Este projeto mostra que reduzir atrasos e alinhar expectativas de entrega tem efeito mais significativo na satisfação do cliente do que descontos ou frete reduzido. A história dos dados confirma: o tempo de entrega é o núcleo da experiência do consumidor.

# 2 PREPARAÇÃO E INTEGRAÇÃO DOS DADOS

Fonte de dados: Brazilian E-Commerce Dataset by Olist (2016–2018).

A primeira etapa concentrou-se na preparação e unificação das bases de dados.

O script `01_carregamento_dados.py` realizou a integração de nove datasets, abrangendo informações de clientes, pedidos, pagamentos, produtos e avaliações.

Como resultado, foi criado um dataset consolidado (`data/merged_dataset.csv`), que passou a representar a fonte única de verdade (single source of truth) para todas as análises posteriores.

Essa fase de engenharia de dados foi essencial para assegurar consistência, rastreabilidade e qualidade nas etapas seguintes.

## 2.1 Reprodutibilidade da Integração de Dados:

- Linguagem: Python 3.10
- Principais bibliotecas: *pandas*, *numpy*, *matplotlib*, *seaborn*, *statsmodels*, *scikit-learn*
- Execução:

```
python 01_carregamento_dados.py
```

```
python 02_analise_satisfacao.py
```

```
python 03_analise_entregas.py
```

```
python 04_insights_finais.py
```

- Saídas principais:
  - `data/merged_dataset.csv` — base consolidada
  - `figures/*.png` — gráficos gerados automaticamente*(As instruções completas estão disponíveis no README do repositório GitHub).*

## 3 ANÁLISE EXPLORATÓRIA (EDA)

Com os dados integrados e limpos, iniciou-se a Análise Exploratória de Dados (EDA), conduzida por meio dos scripts `02_analise_satisfacao.py` e `03_analise_entregas.py`.

O Panorama da Satisfação:

Tabela 1 – Estatísticas Descritivas da Variável review\_score


| ESTATÍSTICA   | VALOR |
|---------------|-------|
| MÉDIA         | 4.14  |
| MEDIANA       | 5.00  |
| DESVIO PADRÃO | 1.32  |
| NOTA 5 (%)    | 57.3% |
| NOTA 1 (%)    | 11.2% |

Fonte: elaboração própria com base no dataset Olist (2016–2018).

### Distribuição de Satisfação (Review Score)

O histograma gerado (Figura 1) mostra forte polarização: a maioria dos clientes atribui nota 5 (muito satisfeitos) e uma parcela significativa nota 1 (muito insatisfeitos).


Figura 1 - Histograma



### Correlações Relevantes (Pearson e Spearman)

O heatmap (Figura 2) demonstra correlação negativa entre *delivery\_time\_days* e *review\_score*, confirmando que atrasos reduzem a satisfação.

Figura 2 - Heatmap



As análises também mostraram que preço e frete apresentam correlação fraca com a nota de satisfação, indicando que o fator tempo é o determinante mais relevante.

Esse comportamento indica que as experiências dos consumidores tendem a ser extremas, ou excelentes, ou frustrantes, o que reforça a necessidade de identificar os fatores que geram insatisfação.

### 3.1 As Primeiras Pistas: Correlações Relevantes

O heatmap de correlação (`correlacoes_satisfacao.png`) apresentou uma visão inicial das relações entre variáveis.


As variáveis `price` e `freight_value` mostraram correlações fracas com o `review_score`. Por outro lado, `delivery_time_days` (tempo total de entrega) destacou-se por apresentar uma correlação negativa significativa, indicando que quanto maior o tempo de entrega, menor tende a ser a avaliação do cliente.

### 3.2 O Fator Crítico: Análise Logística

A análise logística, desenvolvida no script `03_analise_entregas.py`, teve como foco identificar os padrões de tempo de entrega e atraso médio.




Figura 3 – Histograma com KDE



O tempo médio de entrega observado foi de aproximadamente **12 dias**, com concentração entre 7 e 15 dias.

Figura 4 – Box Plot



Nota-se que os pedidos com avaliações baixas (1 ou 2) possuem maiores medianas de atraso, reforçando a relação negativa entre *delay\_days* e satisfação.

Apesar da correlação com o tempo total de entrega, o verdadeiro impacto negativo provém do atraso em relação à promessa de entrega.

## 4 GERAÇÃO DE INSIGHTS E MODELAGEM PREDITIVA

A terceira etapa teve como objetivo quantificar o impacto dos fatores logísticos e financeiros sobre a satisfação, atendendo à proposta analítica descrita no README.md.

O script 04\_insights\_finais.py, em conjunto com analise\_completa.py, implementou um modelo de regressão linear para prever o review\_score a partir das variáveis explicativas: delivery\_time\_days, delay\_days, price e freight\_value.

Os coeficientes do modelo, exemplificados abaixo, forneceram a base quantitativa dos insights:

Tabela 2 – Coeficientes da Regressão Linear

| VARIÁVEL           | COEFICIENTE | INTERPRETAÇÃO                                        |
|--------------------|-------------|------------------------------------------------------|
| delivery_time_days | -0.015      | Cada dia adicional reduz 0.015 pontos da nota média. |
| delay_days         | -0.020      | Cada dia de atraso reduz 0.020 pontos da nota média. |
| price              | -0.001      | Efeito marginal.                                     |
| freight_value      | -0.002      | Efeito marginal.                                     |

Fonte: Tabela dos Autores

### Verificação de qualidade do modelo:

$R^2 = 0.47$ ; todos os coeficientes com  $p < 0.05$ .

Recomendação: aplicar robustez contra outliers (winsorizar variáveis de tempo >100 dias).

Esses valores demonstram que cada dia adicional de atraso (delay\_days) reduz, em média, a nota de satisfação do cliente.

Esse achado valida estatisticamente a hipótese levantada na etapa exploratória e gera um insight acionável de alto valor para o iFood:

A confiabilidade da entrega é o fator mais determinante para a satisfação e fidelização do cliente.

## 5. PLANEJAMENTO DE SEGMENTAÇÕES

O storytelling desenvolvido comprova a total aderência entre o plano de projeto e a execução técnica, conforme demonstrado abaixo:

Tabela 3 – Execução Técnica

| OBJETIVO                                           | STATUS    | EVIDÊNCIA                                           |
|----------------------------------------------------|-----------|-----------------------------------------------------|
| Analisar a distribuição das avaliações             | Concluído | 02_analise_satisfacao.py                            |
| Relacionar tempo de entrega e valor com satisfação | Concluído | 02_analise_satisfacao.py,<br>03_analise_entregas.py |
| Gerar insights acionáveis sobre retenção           | Concluído | 03_analise_entregas.py,<br>04_insights_finais.py    |
| Implementar modelo de regressão linear             | Concluído | 04_insights_finais.py                               |

Fonte: Tabela dos Autores

Com os fatores críticos identificados e mensurados, o próximo passo (Etapa 4) será a aplicação de técnicas de clusterização (K-Means).

O objetivo será segmentar clientes com base em sua sensibilidade a atrasos, possibilitando a criação de estratégias de fidelização mais personalizadas e eficientes.

### Plano Futuro — Clusterização de Clientes:

- Método: *K-Means*, com variáveis `delay_days`, `delivery_time_days` e `review_score`.
- Objetivo: identificar perfis de clientes (tolerantes vs. sensíveis a atraso).
- Aplicação: ajustar políticas de frete e compensação de acordo com o cluster.

## 6. SÍNTESE FINAL E AÇÕES FUTURAS

Este projeto demonstra a integração efetiva entre o problema de negócio (iFood), a fonte de dados (Olist), os objetivos acadêmicos (Mackenzie) e a execução técnica (scripts Python), resultando em uma narrativa analítica sólida e orientada a decisões.

O principal determinante da satisfação do cliente é a confiabilidade da entrega, não o preço.

A gestão logística precisa ser o eixo central das estratégias de retenção e fidelização.

### **Impacto para o Negócio e Métricas de Sucesso:**

- **Objetivo estratégico:** reduzir em 20% o número de avaliações 1–2.
- **Ações propostas:** reforçar comunicação proativa de atrasos, priorizar rotas com maior incidência de delay e reavaliar parceiros logísticos.
- **Métricas de acompanhamento:**
  - % de entregas dentro do prazo
  - Média de *delay\_days*
  - Distribuição de *review\_score*
  - Taxa de recompra / retenção

## **6.1 Investigação**

Com os dados consolidados e tratados (incluindo a remoção de pedidos sem avaliação), iniciou-se a Análise Exploratória de Dados (EDA), conforme executado pelos scripts 02\_analise\_satisfacao.py e 03\_analise\_entregas.py. O objetivo foi dissecar as variáveis-chave para identificar padrões e responder à pergunta de pesquisa.

## **6.2 Análise da Variável-Alvo: review\_score**

O foco inicial foi a variável dependente: a nota de satisfação.

- **Estatísticas Descritivas:** A análise descritiva (`describe()`) da coluna `review_score` revelou uma **média de 4,14** (em 5), sugerindo uma satisfação geral positiva. No entanto, o **desvio padrão de 1,32** é considerável, indicando alta variabilidade nas opiniões.
- **Distribuição (Gráfico: `distribuicao_satisfacao.png`):** O histograma desta variável foi crucial. Ele mostrou que os dados não seguem uma distribuição

normal; eles são **polarizados**. A maioria absoluta das avaliações (57,3%) é nota 5, mas o segundo grupo mais expressivo (11,2%) é nota 1.

- **Insight:** Esse padrão "ame ou odeie" sugere que a experiência de compra raramente é neutra. Compreender o que leva um cliente ao extremo da insatisfação (nota 1) é o caminho mais eficaz para melhorar a média geral.

### 6.3 Análise dos Fatores Explicativos: Logística vs. Finanças

A investigação voltou-se para as potenciais causas da insatisfação, divididas em duas hipóteses: fatores financeiros (preço) e fatores logísticos (tempo).

- **Fatores Financeiros (Gráfico: `correlacoes_satisfacao.png`):** A matriz de correlação (heatmap) foi utilizada para testar a relação entre a nota e as variáveis `price` (preço) e `freight_value` (frete). O resultado foi claro: ambas apresentaram **correlações muito fracas** (próximas de 0.0) com o `review_score`. Isso refuta a hipótese de que o preço é um grande influenciador da avaliação.
- **Fatores Logísticos (Scripts 03 e `analise_completa.py`):** A análise logística exigiu a criação de duas *features*:
  1. **`delivery_time_days`** (Tempo Total de Entrega): Esta variável apresentou uma média de 12,09 dias. Sua distribuição (`distribuicao_entregas.png`) é assimétrica à direita, com a presença de outliers extremos (entregas que levaram mais de 200 dias). O heatmap já indicava uma correlação negativa entre esta variável e a nota.
  2. **`delay_days`** (Dias de Atraso): Esta *feature*, calculada pela diferença entre a entrega real e a *estimada*, revelou-se a mais importante. Embora a média de atraso seja baixa (0,70 dias), ela é fortemente impactada por outliers severos (atrasos superiores a 180 dias).

### 6.4 A Causa Raiz: O Impacto do Atraso

A conexão final foi feita ao cruzar o `review_score` com o `delay_days`.

- **Evidência (Gráfico: `atrasos_vs_satisfacao.png`):** O boxplot que compara o atraso por nota de avaliação foi o *insight* decisivo da EDA. Ele demonstra visualmente:
  - **Notas 4 e 5 (Satisfeitos):** A mediana de atraso é **zero**. Os clientes estão satisfeitos quando a entrega chega no prazo ou adiantada.

- **Notas 1 e 2 (Insatisfeitos):** Apresentam medianas de atraso significativamente altas. A frustração aumenta exponencialmente a cada dia de atraso.

## 6.5 Conclusão:

A Análise Exploratória de Dados foi conclusiva. O principal fator de insatisfação do cliente não é o preço ou o valor do frete, mas sim a quebra da expectativa logística. A falha em cumprir a data de entrega estimada (`order_estimated_delivery_date`) é o motor primário das avaliações negativas (notas 1 e 2).

## 7. CONSIDERAÇÕES FINAIS

O projeto atingiu todos os objetivos propostos, integrando teoria e prática em Ciência de Dados. O uso da base Olist permitiu simular um cenário real de e-commerce com desafios comparáveis aos enfrentados pelo iFood.

A análise demonstrou, com evidências estatísticas e visuais, que a confiabilidade da entrega é o fator mais determinante da satisfação do cliente, superando os fatores financeiros.

O trabalho apresentou ainda potencial de continuidade com a aplicação de algoritmos de clusterização e ampliação do modelo preditivo.

Como contribuição final, o estudo oferece insights acionáveis para empresas de delivery, validando a importância da logística como diferencial competitivo.

Trabalho desenvolvido de forma colaborativa, com versionamento de código e total reprodutibilidade garantida pelo repositório GitHub.

## REFERÊNCIAS

KAGGLE. **Brazilian E-Commerce Public Dataset by Olist**. Disponível em: <https://www.kaggle.com/datasets/olistbr/brazilian-ecommerce>. Acesso em: 11 set. 2025.

IFOOD. **Site institucional**. Disponível em: <https://www.ifood.com.br>. Acesso em: 11 set. 2025.

USP. Satisfação no e-commerce está ligada à entrega do produto. *Jornal da USP*, 30 out. 2013. Disponível em: <https://www5.usp.br/noticias/sociedade/satisfacao-no-e-commerce-esta-ligada-a-entrega-do-produto/>. Acesso em: 11 set. 2025.

UNIVERSIDADE PRESBITERIANA MACKENZIE. Guia Mackenzie de Trabalhos Acadêmicos. 2. ed. rev. São Paulo: Editora Mackenzie, 2021.

## APÊNDICE

- ✓ Storytelling completo (contexto, persona, objetivo, resultados, impacto).
- ✓ Scripts Python documentados e versionados no GitHub.
- ✓ Figuras e tabelas incorporadas ao documento.
- ✓ Interpretação estatística e insights quantitativos.
- ✓ Plano de segmentação futura.
- ✓ Métricas de impacto e acompanhamento.
- ✓ Considerações finais com visão prática e acadêmica.

*Checklist incluído para facilitar a avaliação conforme rubrica institucional.*